

TECH CHALLENGE - FASE 2

Pipeline de Dados

Análise Integrada da Alfabetização Infantil no Brasil

AMBIENTE

AWS Nuvem Serverless (S3 & Glue)

Contexto & Desafio Educacional

Compromisso Nacional Criança Alfabetizada

A meta nacional estabelece que **100% das crianças brasileiras** devem estar plenamente alfabetizadas até o término do 2º ano do Ensino Fundamental.

Com base no estudo **Alfabetiza Brasil (INEP, 2023)**, determinou-se a nota de corte de **743 pontos** na escala Saeb como o limiar de proficiência da criança alfabetizada.

A Dor da Engenharia: Para planejar ações e mitigar desigualdades, é fundamental integrar dados de múltiplos sistemas fragmentados (metas municipais, dados territoriais e microdados de proficiência).

Objetivos Técnicos da Engenharia

Integração de Sistemas

Desenvolver um ecossistema escalável de processamento distribuído capaz de convergir fontes heterogêneas de metas e microdados de desempenho individualizado.

- Arquitetura Medalhão Consolidada
- Ingestão escalável na nuvem AWS

Qualidade & Governança

Garantir a integridade absoluta dos dados transformados aplicando regras rígidas de validação de qualidade, monitoramento e estratégias eficientes de FinOps.

- Testes estritos de integridade relacional
- Otimização inteligente de armazenamento (Parquet)

Arquitetura Proposta

Infraestrutura Nuvem AWS


O ecossistema adota uma abordagem moderna e escalável utilizando **AWS Glue** de forma totalmente serverless. O armazenamento é feito utilizando **Amazon S3**.

Vantagem: Elimina a necessidade de gerenciar servidores físicos e ajusta dinamicamente a computação conforme a carga de trabalho.

Estratégia do Fluxo de Dados



Estratégia do Fluxo de Dados



Visão completa do workflow AWS Glue

Camada Bronze: Ingestão e Rastreabilidade

- **Conversão Colunar Otimizada:** Converte nativamente arquivos estruturados de CSV brutos da Landing Zone diretamente para o formato **Apache Parquet**.
- **Injeção de Metadados de Auditoria:** Enriquece cada registro com carimbos essenciais para linhagem: *_ingestion_timestamp*, *_source_file* e a hash de validação *_record_hash*.
- **Particionamento de Ingestão:** Particionado no Data Lake por ano e mês de ingestão (*_ing_ano* / *_ing_mes*), reduzindo custos de leitura.

Camada Silver: Modelagem Dimensional

Tratamento & Enriquecimento

Garante o saneamento da base com tratamento de nulos, mapeamento correto de redes de ensino municipais/estaduais e remoção de redundâncias.

Criação do Modelo de Fatos

Consolida tabelas fato integradas, permitindo análises granulares instantâneas ao correlacionar notas com dados territoriais.

ALUNOS
fct_avaliacao_aluno

METAS
fct_meta_municipio
fct_meta_uf

Camada Gold: Dados Analíticos Prontos

Visão de Metas

Consolidado por estado, município e rede pública, validando se a meta educacional anual foi alcançada com sucesso.

Métricas Escolares

Desempenho por instituição, computando taxas de comparecimento, média e desvio padrão de proficiência.

Prontidão para IA

Estruturação da tabela ml_aluno contendo dados para treinamento de aprendizado de máquina.

Otimização de Custos em Cloud

Decisões Arquiteturais Econômicas

1. Armazenamento Compactado

Uso estrito de formato Parquet com alta compressão colunar, reduzindo o custo por GB armazenado no S3.

2. Particionamento Inteligente

Filtros de data e ano indexados fisicamente no disco evitam consultas caras e "Full Table Scans" desnecessários via Amazon Athena.

3. Computação Sob Demanda

O AWS Glue cobra por segundo processado. Sem servidores ociosos ou custos de gerência de máquinas virtuais permanentes.

Aplicações Práticas

Modelagem Preditiva

A tabela ***ml_aluno*** provê uma fundação robusta features para treinamento de modelos de Machine Learning.

Features Robustas: Histórico de desempenho escolar, fator de peso amostral e médias contextuais do município.

Variáveis Alvo Limpas: Indicador binário de alfabetização (classificação) e multiclasse de níveis (regressão).

Possibilita treinamento para predição da alfabetização, bem como o nível, de um aluno com base em seu contexto.

ml_aluno	
string	id_aluno
int	feat_rede_encoded
double	feat_peso_aluno
double	feat_media_proficiencia_escola
double	feat_media_portugues_municipio
double	feat_media_portugues_estado
int	target_alfabetizado
string	target_nivel_alfabetizacao

Tabela ml_aluno

Aplicações Práticas

Análise de Dados

As tabelas *consolidado_municipio*, *consolidado_uf* e *distribuicao_niveis* trazem visões macro das taxas de alfabetização, metas e indicadores de referência.

Projetadas para uso em dashboards, permitem analisar estado atual e evolução da taxa de alfabetização, visando identificar desigualdades regionais e disparidades de redes de ensino

consolidado_municipio	
string	sigla_uf
string	nome_municipio
string	rede
double	taxa_alfabetizacao_real
double	meta_alfabetizacao_esperada
double	percentual_participacao
double	taxa_alfabetizacao_referencia_estado
boolean	atingiu_meta
double	diff_meta
string	_gold_processed_at

consolidado_uf	
string	sigla_uf
string	rede
double	taxa_alfabetizacao_real_uf
double	meta_alfabetizacao_esperada_uf
double	percentual_participacao_uf
double	taxa_alfabetizacao_referencia_brasil
boolean	uf atingiu meta
double	diff_meta
string	_gold_processed_at

distribuicao_niveis	
string	sigla_uf
string	nome_municipio
string	rede
string	nivel_alfabetizacao
int	quantidade_alunos
double	percentual_alunos
string	_gold_processed_at

Tabelas para análise de dados

ENCERRAMENTO

Apresentamos uma solução de pipeline moderna, governada e com eficiência financeira, que capacita políticas públicas baseadas em evidências educacionais estruturadas.